最优化方法-习题解答

张彦斌

计算机学院 2014年10月20日

Contents

1	第一章最优化理论基础- $\mathrm{P}13$ 习题 $1(1)$ 、 $2(3)(4)$ 、 3 、 4	1
2	第二章线搜索算法-P27习题2、4、6	4
3	第三章最速下降法和牛顿法P41习题1,2,3	7
4	第四章共轭梯度法P51习题1,3,6(1)	10
5	第五章拟牛顿法P73-2	12
6	第六章信赖域方法P86-8	14
7	第七章非线性最小二乘问题P98-1, 2, 6	18
8	第八章最优性条件P112-1, 2,5,6	23
9	第九章罚函数法P132, 1-(1)、2-(1)、3-(3),6	26
10	第十一章 二次规划习题11 P178-1 (1) 5	29

第一章最优化理论基础-P13习题1(1)、2(3)(4)、3、4

1.验证下列各集合是凸集:

(1) $S = \{(x_1, x_2) | 2x_1 + x_2 \ge 1, x_1 - 2x_2 \ge 1\};$ 需要验证:

根据凸集的定义,对任意的 $x(x_1,x_2),y(y_1,y_2)\in S$ 及任意的实数 $\lambda\in[0,1]$,都

 $\mathbb{F}^p, (\lambda x_1 + (1 - \lambda)y_1, \lambda x_2 + (1 - \lambda)y_2) \in S$

证: $\mathbf{h}x(x_1, x_2), y(y_1, y_2) \in S$ 得到,

$$\begin{cases}
2x_1 + x_2 \ge 1, x_1 - 2x_2 \ge 1 \\
2y_1 + y_2 \ge 1, y_1 - 2y_2 \ge 1
\end{cases}$$
(1)

把(1)中的两个式子对应的左右两部分分别乘以 λ 和 $1-\lambda$.然后再相加,即得

$$\lambda(2x_1 + x_2) + (1 - \lambda)(2y_1 + y_2) \ge 1, \lambda(x_1 - 2x_2) + (1 - \lambda)(y_1 - 2y_2) \ge 1$$
(2)

合并同类项,

$$2(\lambda x_1 + (1 - \lambda)y_1) + (\lambda x_2 + (1 - \lambda)y_2) \ge 1, (\lambda x_1 + (1 - \lambda)y_1) - 2(\lambda x_2 + (1 - \lambda)y_2) \ge 1$$
(3)

证毕.

2.判断下列函数为凸(凹)函数或严格凸(凹)函数:

$$(3) f(x) = x_1^2 - 2x_1x_2 + x_2^2 + 2x_1 + 3x_2$$

首先二阶导数连续可微,根据定理1.5,f在凸集上是

- (I) 凸函数的充分必要条件是 $\nabla^2 f(x)$ 对一切x为半正定;
- (II) 严格凸函数的充分条件是 $\nabla^2 f(x)$ 对一切x为正定。

$$\nabla^2 f(x) = \begin{pmatrix} 2 & -2 \\ -2 & 2 \end{pmatrix} \tag{4}$$

半正定矩阵(4)

$$\nabla^2 f(x) = \begin{pmatrix} 4 & 1 & -3 \\ 1 & 2 & 0 \\ -3 & 0 & 4 \end{pmatrix}$$
 (5)

正定矩阵

 $3.证明 f(x) = \frac{1}{2}x^TGx + b^Tx$ 为严格凸函数当且仅当Hesse矩阵G正定。

证明:根据严格凸函数定义证明。

对任意 $x \neq y$,及任意实数 $\lambda \in (0,1)$ 都有 $f(\lambda x + (1-\lambda)y) < \lambda f(x) + (1-\lambda)f(y)$.

充分性: Hesse矩阵G正定=》严格凸函数.

$$f(\lambda x + (1 - \lambda)y) = \frac{1}{2}(\lambda x + (1 - \lambda)y)^T G(\lambda x + (1 - \lambda)y) + b^T (\lambda x + (1 - \lambda)y)$$

$$\lambda f(x) + (1 - \lambda)f(y) = \lambda(\frac{1}{2}x^TGx + b^Tx) + (1 - \lambda)(\frac{1}{2}y^TGy + b^Ty)$$

$$\begin{array}{l} \lambda f(x) + (1-\lambda)f(y) - f(\lambda x + (1-\lambda)y) = & \lambda(\frac{1}{2}x^TGx) + (1-\lambda)(\frac{1}{2}y^TGy) - \\ [\frac{1}{2}(\lambda x)^TG(\lambda x) + \frac{1}{2}(1-\lambda)y^TG(1-\lambda)y + \frac{1}{2}\lambda x^TG(1-\lambda)y + \frac{1}{2}(1-\lambda)y^TG\lambda x] \\ = & \frac{1}{2}\lambda x^TG(1-\lambda)x + \frac{1}{2}(1-\lambda)y^TG\lambda y - \frac{1}{2}\lambda x^TG(1-\lambda)y - \frac{1}{2}(1-\lambda)y^TG\lambda x \end{array}$$

$$=\frac{1}{2}\lambda x^TG(1-\lambda)(x-y)+\frac{1}{2}(1-\lambda)y^TG\lambda(y-x)$$

 $=\frac{1}{2}\lambda(1-\lambda)(x-y)^TG(x-y)>0$ G正定保障了严格不等式成立。
反之,必要性:严格凸函数=》Hesse矩阵G正定.

类似,当对任意 $x\neq y$,及任意实数 $\lambda\in(0,1)$ 都有 $f(\lambda x+(1-\lambda)y)<\lambda f(x)+(1-\lambda)f(y)$.

$$\begin{array}{l} \lambda f(x) + (1-\lambda)f(y) - f(\lambda x + (1-\lambda)y) = & \lambda(\frac{1}{2}x^TGx) + (1-\lambda)(\frac{1}{2}y^TGy) - \\ [\frac{1}{2}(\lambda x)^TG(\lambda x) + \frac{1}{2}(1-\lambda)y^TG(1-\lambda)y + \frac{1}{2}\lambda x^TG(1-\lambda)y + \frac{1}{2}(1-\lambda)y^TG\lambda x] \\ = & \frac{1}{2}\lambda x^TG(1-\lambda)x + \frac{1}{2}(1-\lambda)y^TG\lambda y - \frac{1}{2}\lambda x^TG(1-\lambda)y - \frac{1}{2}(1-\lambda)y^TG\lambda x \\ = & \frac{1}{2}\lambda x^TG(1-\lambda)(x-y) + \frac{1}{2}(1-\lambda)y^TG\lambda(y-x) \\ = & \frac{1}{2}\lambda(1-\lambda)(x-y)^TG(x-y) > 0 \end{array}$$

4.若对任意 $x \in \Re^n$ 及实数 $\theta > 0$ 都有 $f(\theta x) = \theta f(x)$,证明f(x)在 \Re^n 上为凸函数的充要条件是 $\forall x, y \in \Re^n, f(x+y) \leq f(x) + f(y)$

证明:根据严格凸函数定义证明。

定义: 对任意 $x \neq y$,及任意实数 $\lambda \in (0,1)$ 都有 $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$.

充分条件: $\forall x, y \in \mathbb{R}^n$, 有 $f(x+y) \leq f(x) + f(y)$

对任意 $x \neq y$,及任意实数 $\lambda \in (0,1)$ 都有 $f(\lambda x + (1-\lambda)y) \leq f(\lambda x) + f((1-\lambda)y)$

利用 $f(\theta x) = \theta f(x)$,

$$f(\lambda x + (1 - \lambda)y) \le f(\lambda x) + f((1 - \lambda)y) = \lambda f(x) + (1 - \lambda)f(y).$$

充分性证毕:

必要性: f(x)在 \Re^n 上为凸函数=》 $\forall x, y \in \Re^n, f(x+y) \leq f(x) + f(y)$

根据定义有对任意 $x \neq y$,及任意实数 $\lambda \in (0,1)$ 都有 $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$.

不妨取
$$\lambda = \frac{1}{2},$$
则
$$f(\frac{1}{2}x + (1 - \frac{1}{2})y) \le \frac{1}{2}f(x) + (1 - \frac{1}{2})f(y).$$

利用
$$f(\theta x) = \theta f(x)$$
,

$$f(\frac{1}{2}(x+y)) = \frac{1}{2}f(x+y) \le \frac{1}{2}(f(x)+f(y))$$

$$\forall x, y \in \Re^n, f(x+y) \le f(x) + f(y)$$

证毕!

2 第二章线搜索算法-P27习题2、4、6

第2题:

```
黄金0.618算法:
function [s,phis,k,G,E]=golds(phi,a,b,delta,epsilon)
%输入: phi是目标函数, a, b是搜索区间的两个端点
% delta, epsilon分别是自变量和函数值的容许误差
%输出: s, phis 分别是近似极小点和极大值, G是n \times 4矩阵,
% 其第k行分别是a,p,q,b的第k次迭代值ak,pk,qk,bk,
% E = [ds, dphi],分别是s和phis的误差限
%%%%%%%%%%%%%
t = (sqrt(5)-1)/2; h = b-a;
phia=feval(phi,a); phib=feval(phi,b);
p=a+(1-t)*h; q=a+t*h; phip=feval(phi,p); phiq=feval(phi,q);
k=1; G(k,:)=[a, p, q, b];
while(abs(phib-phia)>epsilon)|(h>delta)
if(phip<phiq)
b=q; phib=phiq; q=p; phiq=phip;
h=b-a; p=a+(1-t)*h; phip=feval(phi,p);
else
a=p; phia=phip; p=q; phip=phiq;
h=b-a; q=a+t*h; phiq=feval(phi,q);
end
```

```
k=k+1; G(k,:)=[a, p, q, b];
end
ds=abs(b-a); dphi=abs(phib-phia);
if(phip<=phiq)
s=p; phis=phip;
else
s=q; phis=phiq;
\quad \text{end} \quad
E=[ds,dphi];
运行: [s, phis, k, G, E] = golds(inline('s^3 - 2 * s + 1'), 0, 3, 0.15, 0.01);
结果
ak,pk,qk,bk
                          0
                                 1.1459 \quad 1.8541 \quad 3.0000
                                 0.7082 \quad 1.1459 \quad 1.8541
                          0
                                 0.4377 \quad 0.7082 \quad 1.1459
                       0.4377
                                 0.7082 \quad 0.8754 \quad 1.1459
                                                                                    (6)
                       0.7082
                                 0.8754 \quad 0.9787 \quad 1.1459
                       0.7082
                                 0.8115 \quad 0.8754
                                                     0.9787
                       0.7082 \quad 0.7721 \quad 0.8115
                                                     0.8754
                       0.7721 \quad 0.8115 \quad 0.8359 \quad 0.8754
[s, phis, k, G, E] = golds(inline('s^3 - 2 * s + 1'), 0, 3, 0.15, 0.001);
\gg G
G =
```

```
0
        1.1459 1.8541
                         3.0000
  0
        0.7082 \quad 1.1459
                         1.8541
  0
        0.4377
                0.7082
                         1.1459
0.4377
        0.7082 \quad 0.8754
        0.8754 \quad 0.9787
0.7082
                         1.1459
                                                    (7)
0.7082
        0.8115
                0.8754
                         0.9787
        0.7721
0.7082
                0.8115
                         0.8754
0.7721
        0.8115
                0.8359
                         0.8754
0.7721
        0.7965 \quad 0.8115
                         0.8359
0.7965
        0.8115 0.8208
                         0.8359
```

第4题:

```
\ggclear all;[s, phis, k, ds, dphi, S] = qmin(inline('s^3 - 2 * s + 1'), 0, 3, 1e - 2, 1e - 4);
```

 \gg s

s =

0.8165

第6题

function f = fun(x)

$$f = 100 * (x(2) - x(1)^{2})^{2} + (1 - x(1))^{2};$$

function gf=gfun(x)

$$gf = [-400 * (x(2) - x(1)^{2}) * x(1) - 2 * (1 - x(1)), 200 * (x(2) - x(1)^{2})]';$$

function mk=armijo(xk,dk)

beta=0.5; sigma=0.2;

m=0; mmax=20;

while (m;=mmax)

$$if(fun(xk + beta^m * dk) \le fun(xk) + sigma * beta^m * gfun(xk)' * dk)$$

mk=m; break;

```
\quad \text{end} \quad
   m=m+1;
   \quad \text{end} \quad
   alpha=beta^m k
   newxk=xk+alpha*dk
   fk=fun(xk)
   newfk = fun(newxk)
   clear all;xk=[-1,1]';dk=[1,1]';mk=armijo(xk,dk)
   alpha =
   0.0020
   newxk =
   -0.9980
1.0020
   \mathrm{fk} =
   4
   newfk =
   3.9956
   mk =
```

3 第三章最速下降法和牛顿法P41习题1,2,3

第1题:

function f=funone(x)

$$f = 3 * x(1)^2 + 2 * x(2)^2 - 4 * x(1) - 6 * x(2);$$

function gf=gfunone(x)

$$gf = [6 * x(1) - 4, 4 * x(2) - 6]';$$

$$\gg x0=[0,1]$$
';[x val k]=grad('funone','gfunone',x0)

x =

0.6667

1.5000

 $\mathrm{val} =$

-5.8333

k =

10

第2题:

(1)牛顿法

function f=funtwo1(x)

$$f = 4 * x(1)^2 + x(2)^2 - 8 * x(1) - 4 * x(2);$$

function gf=gfuntwo1(x)

$$gf = [8 * x(1) - 8, 2 * x(2) - 4]';$$

$$x0{=}[0{,}1]'{;}[x\ val\ k]{=}grad('funtwo1','gfuntwo1',x0)$$

x =

1

2

val =

-8

```
k =
2
 (2) 阻尼牛顿法
function He=Hesstwo(x)
n = length(x);
He=zeros(n,n);
He = [8, 0;
0, 2];
\gg x0=[0,1]';[x val k]=dampnm('funtwo1','gfuntwo1','Hesstwo',x0)
x =
1
2
val =
-8
k =
1
第3题.
function f=fun(x)
f = (x(1) - 2)^4 + (x(1) - 2 * x(2))^2;
function gf = gfun(x)
gf = [4 * (x(1) - 2)^3 + 2 * (x(1) - 2 * x(2)), -4 * (x(1) - 2 * x(2))]';
≫clear all;
```

 $\gg x0=[0\ 3]';[v,val,k]=grad('fun','gfun',x0)$

x =

2.0139

1.0070

val =

3.7685e-008

k =

2111

4 第四章共轭梯度法P51习题1,3,6(1)

1.证明向量 $\alpha_1 = (1,0)^T$ 和 $\alpha_2 = (3,-2)^T$ 关于矩阵

$$A = \begin{pmatrix} 2 & 3 \\ 3 & 5 \end{pmatrix} \tag{8}$$

共轭. 验证 $\alpha_1^T A \alpha_2 = 0$.

3.设 $f(x) = \frac{1}{2}x^THx + b^Tx$,其中

$$H = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}, b = \begin{pmatrix} 3 \\ 3 \end{pmatrix} \tag{9}$$

(1)证明 $d_0 = (1,0)^T$ 与 $d_1 = (-1,2)^T$ 关于H共轭;

(2)以 $x_0 = (0,0)^T$ 为初始点, d_0 和 d_1 为搜索方向,用精确线搜索求f的极小点.

验证 $(1)d_0^T H d_1 = 0.$ (2)首先, $g(\vec{X}) = \nabla f(\vec{X}) = H\vec{X} + b =$

$$\begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 3 \\ 3 \end{pmatrix} \tag{10}$$

用定理4.1,也就是算法4.1产生的迭代序列,则每一步迭代点 x_{k+1} 都是f(x)在 x_0 和方向 d_0,d_1,\ldots,d_k 所张成的线性流形, $S_k=\{x|x=x_0+\sum_{i=0}^k\alpha_id_i,\forall\alpha_i\}$ 中的极小点,特别地, $x_n=x^*=-G^{-1}b$ 是问题的唯一极小点.

精确线搜索得到步长因子 α_k 具有如下性质, $g_{k+1}^T d_k = 0$

$$\begin{cases} \vec{X_{k+1}} = \vec{X_k} + \alpha_k d_k \\ g_{k+1}^T d_k = 0 \end{cases}$$
 (11)

$$\vec{X_{k+1}} = \vec{X_k} + \alpha_k d_k, \ \ \vec{P} \vec{P} \vec{X_1} = \vec{X_0} + \alpha_0 d_0;$$

$$g(\vec{X}_1) = g_1 = g(\vec{X}_1) = H\vec{X}_1 + b, \quad g_1^T d_0 = 0$$

 $\alpha_0 = -3/4, \vec{X}_1 = (-3/4, 0)^T, f(\vec{X}_1) = -9/8;$ 同理,利用(11)迭代,即

$$\begin{cases} \vec{X_2} = \vec{X_1} + \alpha_1 d_1 \\ g_2^T d_1 = 0 \end{cases}$$
 (12)

$$\alpha_1 = -1/4; \vec{X}_2 = (-1/2, -1/2)^T, f(\vec{X}_2) = -3/2,$$

$$f(\vec{X_2}) < f(\vec{X_1}),$$

定理4.1保证了极小点为 $\vec{X}_2 = (-1/2, -1/2)^T$

$$6.(1)f(x)=4x_1^2+4x_2^2-4x_1x_2-12x_2$$
,取初始点 $x_0=(-0.5,1)^T;$ $g(x)=
abla f(x)=Gx+b, G(x)=
abla^2f(x)=G;$

共轭方向的构造过程,取初始方向 $d_0=-g_0$,令 $x_1=x_0+\alpha_0d_0$,其中 $\nabla f(x_1)^Td_0=g_1^Td_0=0$,在 x_1 处,用f在 x_1 的负梯度方向 $-g_1$ 与 d_0 的组合来生成 d_1 ,即 $d_1=-g_1+\beta_0d_0$,然后选取系数 β_0 ,使得 d_1 与 d_0 关于G共轭,即令 $d_1^TGd_0=0$ 确定 β_0 .因此, $\beta_0=\frac{g_1^TGd_0}{d_0^TGd_0},g_1-g_0=G(x_1-x_0)=\alpha_0Gd_0$,

利用定理4.1可知 $g_2^T d_i = 0 (i = 0, 1)$ 计算过程:

$$g(x) = Gx + b = \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 0 \\ -12 \end{pmatrix}$$
 (13)

$$G = \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \tag{14}$$

$$d_0 = -g(x0) = -Gx - b = -\begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} -0.5 \\ 1 \end{pmatrix} - \begin{pmatrix} 0 \\ -12 \end{pmatrix} = \begin{pmatrix} 8 \\ 2 \end{pmatrix}$$
(15)

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} -0.5 \\ 1 \end{pmatrix} + \alpha_0 \begin{pmatrix} 8 \\ 2 \end{pmatrix} = \begin{pmatrix} 8\alpha_0 - 0.5 \\ 2\alpha_0 + 1 \end{pmatrix}$$
 (16)

$$\nabla f(x_1)^T d_0 = g_1^T d_0 = 0$$

$$g_1^T d_0 = \begin{bmatrix} \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} 8\alpha_0 - 0.5 \\ 2\alpha_0 + 1 \end{pmatrix} + \begin{pmatrix} 0 \\ -12 \end{pmatrix} \end{bmatrix}^T \begin{pmatrix} 8 \\ 2 \end{pmatrix} = 0$$
 (17)

$$\alpha_0 = 17/104, x_1 = (21/26, 69/52)^T \approx (0.80769, 1.32692)^T$$

$$g_1 = (15/13, -60/13)^T$$

$$\beta_0 = \frac{g_1^T G d_0}{d_0^T G d_0} = 225/676 \approx 0.33284$$

$$d_1 = -g_1 + \beta_0 d_0 = (3315/2197, 23205/4394)^T \approx (1.5088757, 5.281065)^T;$$

$$x_2 = x_1 + \alpha_1 d_1; \nabla f(x_2)^T d_1 = g_2^T d_1 = 0$$

$$x_2 = \begin{pmatrix} (255\alpha_1)/169 + 21/26\\ (1785\alpha_1)/338 + 69/52 \end{pmatrix}$$
 (18)

$$g_2 = \begin{pmatrix} 15/13 - (1530\alpha_1)/169\\ (6120\alpha_1)/169 - 60/13 \end{pmatrix}$$
 (19)

由此可以求出 $\alpha_1 = 0.127450980392157$;

极值点为 $X_2 = (1,2)^T$;

5 第五章拟牛顿法P73-2

2.DFP程序算法调用

极值点 $x = (-0.2203 \times 10^{-6}, -0.1599 \times 10^{-6});$ 极小值val= 1.2527×10^{-13}

附程序:

function [x,val,k]=dfp(fun,gfun, x_0)

% 功能: 用DFP算法求解无约束问题: min f(x)

% 输入: x_0 是初始点, fun, gfun分别是目标函数及其梯度

%输出: x,val分别是近似最优点和最优值, k是迭代次数。

maxk=1e5; % 给出最大迭代次数

 $\rho = 0.55; \sigma = 0.4; \epsilon = 1e-5;$

 $k=0; n=length(x_0);$

%Hk=inv(feval('Hess', x_0));

%Hk = eye(n);

```
Hk=[2\ 1;1\ 1];
while(k<maxk)
   gk=feval(gfun,x<sub>0</sub>);% 计算梯度
   if(norm(gk) < \epsilon),break;end % 检验终止准则
   dk=-Hk*gk;% 计算搜索方向
   m=0;mk=0;
   while(m<20) % 用Armijo搜索求步长
      if(feval(fun, x_0 + \rho^m * d_k) < feval(fun, x_0) + \sigma * \rho^m * g'_k * d_k)
        mk=m;break;
      end
      m=m+1;
   \quad \text{end} \quad
   %DFP校正
   x = x_0 + \rho^m k * d_k;
   sk=x-x_0;yk=feval(gfun,x)-gk;
   if(sk'*yk>0)
      Hk=Hk-(Hk*yk*yk'*Hk)/(yk'*Hk*yk)+(sk*sk')/(sk'*yk);
   \quad \text{end} \quad
   k=k+1; x_0=x;
end
val=feval(fun,x0);
 (I) 当
                               H_0 = \left(\begin{array}{cc} 2 & 1\\ 1 & 1 \end{array}\right)
                                                                                 (20)
```

```
[x,val,k]=dfp('fun','gfun',[1,-1]')
x =
   1.0e-006*
   -0.220306134442640
   -0.159928197216675
val =
   1.252658776679855e-013
k =
    4
 (II) 当采用%Hk=inv(feval('Hess',x0));
[x,val,k] \hspace{-0.05cm} = \hspace{-0.05cm} dfp('fun','gfun',[1,\hspace{-0.05cm}-\hspace{-0.05cm}1]')
x =
    0
    0
val =
    0
k =
    1
```

6 第六章信赖域方法P86-8

8(1)>>gk=[-6 -3]';Bk=[4 -4;-4 8];
>> dta=1;

```
>> [d,val,lam,k]=trustq(gk,Bk,dta)
d =
  0.870281791219574\\
  0.492554154744547
val =
  -5.928777686124834
lam =
  5.158202203432865
  5
>> dta=2;
[d,val,lam,k] = trustq(gk,Bk,dta)
d =
  1.726569382044938
  1.009434577568092
val =
  -10.321239036609670
lam =
  1.813689513237923
k =
  7
>> dta=5;
[d,val,lam,k]=trustq(gk,Bk,dta)
d =
```

3.749999980155628

```
2.249999987787719\\
val =
   -14.624999999999998
lam =
   8.078453007598365\mathrm{e}\text{-}009
k =
   4
(2)
>> gk=[1 -3 -2]';Bk=[3 -1 2;-1 2 0;2 0 4];
dta=1;
[d,val,lam,k] = trustq(gk,Bk,dta)
d =
   -0.262643366009954
   0.837433127446609\\
   0.479295543075525
val =
   -2.501140183861169
lam =
   1.268746535391740
k =
   7
>> dta=2;
```

[d,val,lam,k] = trustq(gk,Bk,dta)

 $\mathrm{val} =$

-2.8333333333333333

0.66666666628600

lam =

 $2.286320834416492 \mathrm{e}\hbox{-}010$

k =

4

7 第七章非线性最小二乘问题P98-1, 2, 6

1. 设有非线性方程组

$$f_1(x) = x_1^3 - 2x_2^2 - 1 = 0$$

$$f_2(x) = 2x_1 + x_2 - 2 = 0$$
(21)

(1)列出求解这个方程组的非线性最小二乘问题的数学模型;

最小二乘问题的数学表达式: $min_{x \in R^n} f(x) = \frac{1}{2} \|F(x)\| = \frac{1}{2} \sum_{i=1}^m f_i^2(x)$

(2)写出求解该问题的高斯-牛顿法迭代公式的具体形式:

$$J_k = F'(x(k)) = (\nabla F_1(x(k)), \dots, \nabla F_m(x(k)))^T = \begin{pmatrix} 3x_{1,k}^2 & -4x_{2,k} \\ 2 & 1 \end{pmatrix}$$
 (22)
$$d_k^{GN} = -[J_k^T J_k]^{-1} J_k^T F(x_k) =$$

$$\begin{bmatrix} \begin{pmatrix} 3x_{1,k}^2 & 2 \\ -4x_{2,k} & 1 \end{pmatrix} \begin{pmatrix} 3x_{1,k}^2 & -4x_{2,k} \\ 2 & 1 \end{pmatrix} \end{bmatrix}^{-1} \begin{pmatrix} 3x_{1,k}^2 & 2 \\ -4x_{2,k} & 1 \end{pmatrix} \begin{pmatrix} x_{1,k}^3 - 2x_{2,k}^2 - 1 \\ 2x_{1,k} + x_{2,k} - 2 \end{pmatrix} \tag{23}$$

(3)初始点取为 $x_0 = (2,2)^T$,迭代三次:

迭代公式:

$$X_{k+1} = X_k + d_k^{GN}$$

$$X_1 = X_0 + d_0^{GN} =$$

3.107142857142859

3.785714285714287

$$X_2 = X_1 + d_1^{GN} =$$

5.157431640715118

7.685136718569831

$$X_3 = X_2 + d_2^{GN} =$$

8.766682264589718

16.466635470820520

2.

解答: (1) 测得的 t_1, t_2 和y一共5组数据,分别代入关系式

$$y = \frac{x_1 x_3 t_1}{1 + x_1 t_1 + x_2 t_2} \tag{24}$$

$$\begin{cases}
0.13 = \frac{x_1 x_3}{1 + x_1 + x_2} \\
0.22 = \frac{2x_1 x_3}{1 + 2x_1 + x_2} \\
0.08 = \frac{x_1 x_3}{1 + x_1 + 2x_2} \\
0.13 = \frac{2x_1 x_3}{1 + 2x_1 + 2x_2} \\
0.19 = \frac{0.1 x_1 x_3}{1 + 0.1 x_1}
\end{cases} (25)$$

$$\begin{cases}
F_1(x) = x_1 x_3 - 0.13(1 + x_1 + x_2) \\
F_2(x) = 2x_1 x_3 - 0.22(1 + 2x_1 + x_2) \\
F_3(x) = x_1 x_3 - 0.08(1 + x_1 + 2x_2) \\
F_4(x) = 2x_1 x_3 - 0.13(1 + 2x_1 + 2x_2) \\
F_5(x) = 0.1x_1 x_3 - 0.19(1 + 0.1x_1)
\end{cases} (26)$$

(1)最小二乘问题模型表示为 $min_{x \in R^n} f(x) = \frac{1}{2} \|F(x)\| = \frac{1}{2} \sum_{i=1}^m F_i^2(x)$

(2)高斯牛顿迭代公式的具体公式为:

$$d_k^{GN} = -[J_k^T J_k]^{-1} J_k^T F(x_k)$$

6.利用LM方法的matlab程序求解 $minf(x)=\frac{1}{2}\sum_{i=1}^{5}r_{i}^{2}(x)$ 其中

$$\begin{cases}
 r_1(x) = x_1^2 + x_2^2 + x_3^2 - 1 \\
 r_2(x) = x_1 + x_2 + x_3 - 1 \\
 r_3(x) = x_1^2 + x_2^2 + (x_3 - 2)^2 - 1 \\
 r_4(x) = x_1 + x_2 - x_3 + 1 \\
 r_5(x) = x_1^3 + 3x_2^2 + (5x_3 - x_1 + 1)^2 - 36t
\end{cases} (27)$$

t为参数,可取t=0.5,1,5等,注意当t=1时, $x^*=(0,0,1)^T$ 是全局极小点,这时问题为零残量,比较不同参数的计算效果。

function [x,val,k]=lmm(Fk,JFk,x0)

%功能: 用L-M方法求解非线性方程组: F(x)=0

%输入: x0是初始点, Fk, JFk 分别是求F(xk)及F'(xk)的函数

%输出: x, val分别是近似解及——F(xk)——的值, k是迭代次数.

maxk=1000; %给出最大迭代次数

```
\rho = 0.55; \sigma = 0.4; \mu_k = norm(feval(Fk, x0));
k=0; epsilon=1e-6; n=length(x0);
while(k<maxk)
   fk=feval(Fk,x0); %计算函数值
   jfk=feval(JFk,x0); %计算Jacobi阵
   gk=jfk'*fk;
  dk = -(jfk'*jfk + \mu_k*eye(n)) \setminus gk; % 解方程组Gk*dk=-gk, 计算搜索方向
   if(norm(gk)jepsilon), break; end %检验终止准则
   m=0; mk=0;
   while(m<20) % 用Armijo搜索求步长
      newf = 0.5*norm(feval(Fk, x0 + \rho^m * dk))^2;
      oldf = 0.5 * norm(feval(Fk, x0))^2;
      if(newf < oldf + sigma * \rho^m * gk' * dk)
         mk=m; break;
      end
      m=m+1;
   \quad \text{end} \quad
   x0 = x0 + \rho^m k * dk;
   muk=norm(feval(Fk,x0));
   k=k+1;
\quad \text{end} \quad
x=x0;
val=0.5*\mu_k^2;
```

%gval=norm(gfun(x));

%% 目标函数

(I)t = 0.5

function y=Fk(x)

$$y(1) = x(1)^2 + x(2)^2 + x(3)^2 - 1;$$

$$y(2) = x(1) + x(2) + x(3) - 1;$$

$$y(3) = x(1)^2 + x(2)^2 + (x(3) - 2)^2 - 1;$$

$$y(4) = x(1) + x(2) - x(3) + 1;$$

$$y(5) = x(1)^3 + 3 * x(2)^2 + (5 * x(3) - x(1) + 1)^2 - 36 * 0.5;$$

$$y = y(:);$$

%%%% Jacobi 阵%%%%%%function JF=JFk(x)

$$JF = [2*x(1), 2*x(2), 2*x(3);$$

1, 1, 1;

$$2*x(1),2*x(2),2*(x(3)-2);$$

1, 1 -1;

$$3 * x(1)^2 - 2 * (5 * x(3) - x(1) + 1), 6 * x(2), 10 * (5 * x(3) - x(1) + 1)];$$

$$>> x0 = [1, 1, 1]'; [x, val, k] = lmm('Fk', 'JFk', x0)$$

x =

0.339361063668441

-0.200183578804671

0.714384339944574

val =

0.486062168183995

```
k =
  9
(II)t=1;注意,这里x^* = (0,0,1)^T是全局极小点,这时问题为零残量。
>> clearall; x0 = [1, 1, 1]'; [x, val, k] = lmm('Fk', 'JFk', x0)
x =
  0.000000000000087
  0.99999999999985
val =
  2.815888304992978 \mathrm{e}\hbox{-}027
k =
  8
(III)t=5;
>> clearall; x0 = [1, 1, 1]'; [x, val, k] = lmm('Fk', 'JFk', x0)
x =
  -0.490713830929549
  0.103144026198463
  2.384345136824180
val =
  14.450411547247533
k =
```

14

8 第八章最优性条件P112-1, 2,5,6

1.验证 $\bar{x} = (2,1)^T$ 是否为下列最优化问题的KT点:

min
$$f(x) = (x_1 - 3)^2 + (x_2 - 2)^2$$

s.t. $x_1^2 + x_2^2 \le 5$,
 $x_1 + 2x_2 = 4$,
 $x_1, x_2 > 0$. (28)

验证: 计算

$$\nabla f(\bar{x}) = \begin{bmatrix} 2(x_1 - 3) \\ 2(x_2 - 2) \end{bmatrix} \bigg|_{x = \bar{x}} = \begin{bmatrix} -2 \\ -2 \end{bmatrix}, \nabla h(\bar{x}) = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$
 (29)

$$\nabla g_1(\bar{x}) = \begin{bmatrix} -2x_1 \\ -2x_2 \end{bmatrix} = \begin{bmatrix} -4 \\ -2 \end{bmatrix}, \nabla g_2(\bar{x}) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \nabla g_3(\bar{x}) = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$
(30)

令

$$\nabla f(\bar{x}) - \bar{\mu} \nabla h(\bar{x}) - \bar{\lambda_1} \nabla g_1(\bar{x}) = 0$$

即

所以

$$\begin{cases} \nabla f(\bar{x}) - \bar{\mu} \nabla h(\bar{x}) - \sum_{i=1}^{3} \bar{\lambda_i} \nabla g_i(\bar{x}) = 0 \\ \bar{\lambda_i} g_i(\bar{x}) = 0, \bar{\lambda_i} \ge 0, i = 1, 2, 3 \end{cases}$$
 (32)

这表明 \bar{x} 是KT点, $(\bar{x},(\bar{\mu},\bar{\lambda}))$ 是KT对, 其中 $\bar{\mu}=-\frac{2}{3},\bar{\lambda}=(\frac{1}{3},0,0)^T$.

2.对于最优化问题:

$$\begin{aligned} & \min \quad f(x) = 4x_1 - 3x_2 \\ & s.t. \quad -(x_1 - 3)^2 + x_2 + 1 \ge 0, \\ & \quad 4 - x_1 - x_2 \ge 0, \\ & \quad x_2 + 7 \ge 0. \end{aligned}$$

求满足KT条件的点。

解: 类似第1题

$$\nabla f(\bar{x}) = \begin{bmatrix} 4 \\ -3 \end{bmatrix} \Big|_{x=\bar{x}} = \begin{bmatrix} 4 \\ -3 \end{bmatrix}, \nabla h(\bar{x}) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$
 (34)

$$\nabla g_1(\bar{x}) = \begin{bmatrix} -2(\bar{x}_1 - 3) \\ 1 \end{bmatrix}, \nabla g_2(\bar{x}) = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \nabla g_3(\bar{x}) = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$
 (35)

令

$$\begin{cases} \nabla f(\bar{x}) - \bar{\mu} \nabla h(\bar{x}) - \sum_{i=1}^{3} \bar{\lambda}_i \nabla g_i(\bar{x}) = 0\\ \bar{\lambda}_i g_i(\bar{x}) = 0, \bar{\lambda}_i \ge 0, i = 1, 2, 3 \end{cases}$$
(36)

即:

$$\begin{cases}
\begin{bmatrix} 4 \\ -3 \end{bmatrix} - \bar{\lambda}_1 \begin{bmatrix} -2(\bar{x}_1 - 3) \\ 1 \end{bmatrix} - \bar{\lambda}_2 \begin{bmatrix} -1 \\ -1 \end{bmatrix} - \bar{\lambda}_3 \begin{bmatrix} 0 \\ 1 \end{bmatrix} = 0 \\
\bar{\lambda}_1(-(\bar{x}_1 - 3)^2 + \bar{x}_2 + 1) = 0 \\
\bar{\lambda}_2(4 - \bar{x}_1 - \bar{x}_2) = 0 \\
\bar{\lambda}_3(\bar{x}_2 + 7) = 0 \\
\bar{\lambda}_i \ge 0, i = 1, 2, 3
\end{cases} (37)$$

$$4 - \bar{x}_1 - \bar{x}_2 = 0 \Longrightarrow \bar{x}_2 = 4 - \bar{x}_1$$

代入
$$-(\bar{x}_1-3)^2+\bar{x}_2+1=0=>$$

$$-(\bar{x}_1-3)^2+4-\bar{x}_1+1=0=>$$

$$\bar{x}_1 = 1$$
 $\dot{x}_1 = 4$

当
$$\bar{x}_1 = 4$$
时, $\bar{x}_2 = 0.\bar{\lambda}_1 = -7/3.\bar{\lambda}_2 = 2/3.$ 不满足 $\bar{\lambda}_i > 0$ 舍去:

当
$$\bar{x}_1 = 1$$
时, $\bar{x}_2 = 3, \bar{\lambda}_1 = 7/3, \bar{\lambda}_2 = 16/3, 满足\bar{\lambda}_i \geq 0$;

5.利用KT条件推出线性规划

$$\begin{array}{ll} min & z=c^Tx\\ s.t. & Ax\leq b,\\ & x\geq 0, \end{array} \tag{38}$$

的最优化条件。

解:

$$\begin{cases}
\nabla f(x) - \sum_{i=1}^{2} \lambda_i \nabla g_i(x) = 0 \\
\lambda_i g_i(x) = 0, \lambda_i \ge 0, i = 1, 2
\end{cases}$$
(39)

 $\nabla g_1(x) = -A,$

 $\nabla g_2(x) = I,$

其拉格朗日函数为

$$L(x, \lambda_1, \lambda_2) = c^T x - \lambda_1^T (b - Ax) - \lambda_2^T x$$

对上述函数关于x求极小. 令

$$\nabla_x L(x, \lambda_1, \lambda_2) = c - \lambda_2 + A^T \lambda_1 = 0,$$

$$由(39)\lambda_2 g_2(x) = \lambda_2 x = 0,$$

 $\diamondsuit \lambda_2 = 0,$

因此最优性条件为:

$$\begin{cases} c + A^T \lambda_1 = 0 \\ \lambda_1 (b - Ax) = 0, \lambda_1 \ge 0 \end{cases}$$
 (40)

6.设二次规划

$$\begin{array}{ll} min & f(x) = \frac{1}{2}x^THx + c^Tx \\ s.t. & Ax = b, \end{array} \tag{41}$$

其中H为n阶对称正定矩阵,矩阵A行满秩,求其最优解并说明解的唯一性。

解:

首先写出该问题的拉格朗日函数为

$$L(x,\lambda) = \frac{1}{2}x^T H x + c^T x - \lambda^T (Ax - b).$$

对上述函数关于x求极小. 由于H对称正定, 故函数 $L(x,\lambda)$ 关于x为凸函数.

$$\nabla_x L(x,\lambda) = Hx + c - A^T \lambda = 0,$$

H对称正定,以及等式约束条件Ax = b,

$$Hx + c - A^T\lambda = 0,$$

$$x + H^{-1}c - H^{-1}A^T\lambda = 0,$$

$$Ax + AH^{-1}c - AH^{-1}A^{T}\lambda = 0.$$

$$b + AH^{-1}c - AH^{-1}A^{T}\lambda = 0.$$

H对称正定,A行满秩,因此, $AH^{-1}A^{T}$ 可逆(需要简单证明),

$$\lambda = (AH^{-1}A^T)^{-1}(b + AH^{-1}c),$$

因此有拉格朗日乘子的唯一性解,

也就有了最优解 $x = -H^{-1}c + H^{-1}A^{T}\lambda$ 的唯一性。

9 第九章罚函数法P132, 1-(1)、2-(1)、3-(3),6

1-(1):用外罚函数法求解下列约束优化问题:

解:

由等式约束得 $x_2=\pm\sqrt{1-x_1^2}$,代入目标函数得到一个无约束的单变量极小化问题

$$min\phi(x_1) = -x_1 \pm \sqrt{1 - x_1^2}$$

其全局极小点为 $x_1=\sqrt{\frac{1}{2}}$,从而得到原问题的全局极小点为 $(\sqrt{\frac{1}{2}},\sqrt{\frac{1}{2}})$.

现在要使构造的罚函数P(x),满足

$$P(x) \begin{cases} = 0, & x_1^2 + x_2^2 - 1 = 0 \\ > 0, & x_1^2 + x_2^2 - 1 \neq 0, \end{cases}$$
 (43)

只要令 $\bar{P}(x) = (x_1^2 + x_2^2 - 1)^2$ 即可. 现在考察目标函数和上述罚函数的组合

$$P(x,\sigma) = f(x) + \bar{P}(x) = -x_1 - x_2 + \sigma \bar{P}(x)$$

其中 $\sigma > 0$ 是充分大的正数,称为罚因子(罚参数)。求这个组合函数的极小点. 由

$$\frac{\partial P(x,\sigma)}{\partial x_1} = \frac{\partial P(x,\sigma)}{\partial x_2} = 0,$$

得

$$\begin{cases}
-1 + 4\sigma x_1(x_1^2 + x_2^2 - 1) &= 0 \\
-1 + 4\sigma x_2(x_1^2 + x_2^2 - 1) &= 0
\end{cases}$$
(44)

由此可得 $x_1=x_2\neq 0$,因此 $x_1(2x_1^2-1)=\frac{1}{4\sigma}$,当 $\sigma\to\infty$, $x_1=0$ (舍去)和 $x_1=\sqrt{\frac{1}{2}}$ 。所以 $x_1=x_2=\sqrt{\frac{1}{2}}$, $minf(x)=-\sqrt{2}$.

2-(1).用内点法求解下列约束优化问题:

(1)

min
$$f(x) = x_1 + x_2$$

s.t. $-x_1^2 + x_2 \le 0$, $x_1 \ge 0$; (45)

—更正-

min
$$f(x) = x_1 + x_2$$

s.t. $-x_1^2 + x_2 \ge 0$, $x_1 \le 0$; (46)

解:

令
$$g_1(x) = x_1^2 - x_2, g_2(x) = x_1,$$
给出增广目标函数为

$$H(x,\tau) = x_1 + x_2 - \tau (\ln(x_1^2 - x_2) + \ln(x_1))$$

令

$$\begin{cases} \frac{\partial H}{\partial x_1} &= 1 - \frac{2\tau x_1}{x_1^2 - x_2} - \frac{\tau}{x_1} = 0\\ \frac{\partial H}{\partial x_2} &= 1 + \frac{\tau}{x_1^2 - x_2} = 0 \end{cases}$$
(47)

$$x_1^2 - x_2 = -\tau, 1 + 2x_1 - \frac{\tau}{x_1} = 0,$$

$$x_1 = \frac{-1 \pm \sqrt{1 + 8\tau}}{4},$$

$$\tau \to 0, x_1 = 0 \, \text{\'ex} \, x_1 = -\frac{1}{2}$$

$$x_1^2 - x_2 = -\tau$$

$$x_2 = 0$$
 if $x_2 = \frac{1}{4}$

当
$$x_1 = -\frac{1}{2}$$
, $x_2 = \frac{1}{4}$ 时min $f(x) = -\frac{1}{4}$.

更正

解:

令
$$g_1(x) = -(x_1^2 - x_2), g_2(x) = -x_1$$
,给出增广目标函数为

$$H(x,\tau) = x_1 + x_2 - \tau (ln(-x_1^2 + x_2) + ln(-x_1))$$

令

$$\begin{cases} \frac{\partial H}{\partial x_1} &= 1 + \frac{2\tau x_1}{-x_1^2 + x_2} - \frac{\tau}{x_1} = 0\\ \frac{\partial H}{\partial x_2} &= 1 - \frac{\tau}{-x_1^2 + x_2} = 0 \end{cases}$$
(48)

$$x_1^2 - x_2 = -\tau, 1 + 2x_1 - \frac{\tau}{x_1} = 0,$$

$$x_1 = \frac{-1 \pm \sqrt{1 + 8\tau}}{4},$$

$$\tau \to 0, x_1 = 0$$
 if $x_1 = -\frac{1}{2}$

$$x_1^2 - x_2 = -\tau$$

$$x_2 = 0 \stackrel{\bullet}{\Rightarrow} x_2 = \frac{1}{4}$$

当
$$x_1 = -\frac{1}{2}$$
, $x_2 = \frac{1}{4}$ 时min $f(x) = -\frac{1}{4}$.

3-(1).用乘子法求解下列问题:

(1)

解:

PHR算法:

我们回到一般约束优化问题(9.28,9.33)(书上),我们来构造求解(49)的乘子法.此时, 增广拉格朗日函数为

$$\psi(x, \mu, \lambda, \sigma) = f(x) - \sum_{i=1}^{l} \mu_i h_i(x) + \frac{\sigma}{2} \sum_{i=1}^{l} h_i^2(x) + \frac{1}{2\sigma} \sum_{i=1}^{m} ([\min\{0, \sigma g_i(x) - \lambda_i\}]^2 - \lambda_i^2)$$

乘子迭代公式为

$$(\mu_{k+1})_i = (\mu_k)_i - \sigma h_i(x_k), i = 1, 2, \cdot, l,$$

$$(\lambda_{k+1})_i = max\{0, (\lambda_k)_i - \sigma g_i(x_k)\}, i = 1, 2, \cdot, m.$$

今

$$\beta_k = (\sum_{i=1}^l h_i^2(x_k) + \sum_{i=1}^m [min\{g_i(x_k), \frac{(\lambda_k)_i}{\sigma}\}]^2)^{\frac{1}{2}}$$

则终止准则为 $\beta_k \leq \varepsilon$

-重要

$$\psi(x,\lambda,\sigma) = f(x) + \frac{1}{2\sigma} ([\min\{0,\sigma x_1 - \lambda_1\}]^2 - \lambda_1^2)$$

令

$$\begin{cases}
\frac{\partial \psi}{\partial x_1} &= 2x_1 = 0, if(\sigma x_1 - \lambda_1) < 0 \\
&= 2x_1 + (\sigma x_1 - \lambda_1), if(\sigma x_1 - \lambda_1) > 0 \\
\frac{\partial \psi}{\partial x_2} &= 2x_2 = 0
\end{cases} (50)$$

--数值方法角度

取初始点 $x_0 = (0,0)^T$, $\lambda_1 = 1$, $\sigma_1 = 2$, $\varepsilon = 1e - 5$ $x_1 = x_2 = 0$, min f(x) = 0

$$x_1 = \frac{\lambda_1}{2+\sigma}, x_2 = 0;$$
或者 $x_1 = 0, x_2 = 0$

$$\sigma \rightarrow \infty, x_1 = 0, x_2 = 0; \min f(\mathbf{x}) = 0$$

6.略。

10 第十一章二次规划习题11 P178-1 (1),5

1.用拉格朗日方法求解下列二次规划问题: (1)

首先写出该问题的拉格朗日函数为

$$L(x,\lambda) = \frac{1}{2}x^T H x + c^T x - \lambda (AX - 1).$$

$$H = \begin{pmatrix} 4 & 1 \\ 1 & 2 \end{pmatrix}, c = \begin{pmatrix} -1 \\ -1 \end{pmatrix}, A = (1,1), \tag{52}$$

对上述函数关于x求极小. 由于H对称正定, 故函数 $L(x,\lambda)$ 关于x为凸函数. \wedge

$$\nabla_x L(x,\lambda) = Hx + c - A^T \lambda = 0,$$

H对称正定,以及等式约束条件Ax = 1,

$$\begin{pmatrix} H & -A^T \\ -A & 0 \end{pmatrix} \begin{pmatrix} x \\ \lambda \end{pmatrix} = \begin{pmatrix} -c \\ -1 \end{pmatrix}, \tag{53}$$

$$\begin{pmatrix} 4 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \lambda \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix}, \tag{54}$$

解得

$$\begin{pmatrix} x_1 \\ x_2 \\ \lambda \end{pmatrix} = \begin{pmatrix} 1/4 \\ 3/4 \\ 3/4 \end{pmatrix}, \tag{55}$$

5.设 $A \in \mathbb{R}^{m \times n}$ 行满秩, $a \in \mathbb{R}^n$,证明二次规划问题

min
$$\frac{1}{2}(x-a)^T(x-a)$$
,
s.t. $Ax = b$; (56)

的解以及相应的拉格朗日乘子分别为:

$$x^* = a + A^T (AA^T)^{-1} (b - Aa), \lambda^* = (AA^T)^{-1} (b - Aa)$$

证明:

二次规划问题等价于

$$\begin{array}{ll} min & \frac{1}{2}x^THx - a^Tx + \frac{1}{2}a^Ta, \\ s.t. & Ax = b; \end{array} \tag{57}$$

其中H单位矩阵E,

对上述函数关于x求极小. 由于H对称正定, 故函数 $L(x,\lambda)$ 关于x为凸函数.

$$\nabla_x L(x,\lambda) = Hx - a - A^T \lambda = 0,$$

H对称正定,以及等式约束条件Ax = b.

$$Hx - a - A^T\lambda = 0,$$

$$x + H^{-1}(-a) - H^{-1}A^T\lambda = 0,$$

$$Ax + AH^{-1}(-a) - AH^{-1}A^{T}\lambda = 0,$$

$$b + AH^{-1}(-a) - AH^{-1}A^{T}\lambda = 0,$$

其中H单位矩阵E,A行满秩,因此, AA^T 可逆(需要简单证明),

$$\lambda = (AA^T)^{-1}(b - Aa),$$

因此有拉格朗日乘子的唯一性解,

也就有了最优解 $x = -H^{-1}(-a) + H^{-1}A^T\lambda = a + A^T(AA^T)^{-1}(b-Aa)$ 的唯一性.